



Bacharelado em Ciência da Computação (2018.1)

SEGMENTAÇÃO DE PÍLULAS ILÍCITAS

Disciplina: Processamento Digital de Imagens

Alunos: José Igor de Carvalho, Renan Camurça

Professor: Nivando Bezerra

1. Introdução

Em visão computacional, **segmentação** se refere ao processo de dividir uma imagem digital em múltiplas regiões (conjunto de pixels) ou objetos, com o objetivo de simplificar e/ou mudar a representação de uma imagem para facilitar a sua análise. Segmentação de imagens é tipicamente usada para localizar objetos e formas (linhas, curvas, etc) em imagens.

O resultado da segmentação de imagens é um conjunto de regiões/objetos ou um conjunto de contornos extraídos da imagem (ver detecção de borda). Como resultado, cada um dos pixels em uma mesma região é similar com referência a alguma característica ou propriedade computacional, tais como cor, intensidade, textura ou continuidade. Regiões adjacentes devem possuir diferenças significativas com respeito a mesma característica

O objetivo deste documento é apresentar três técnicas para segmentar um determinado conjunto de imagens, a saber: Segmentação por Crescimento de Regiões, Segmentação de objetos circulares utilizando a Transformada de Hough e Segmentação utilizando o algoritmo de agrupamento K-Means (ou K-Médias). O conjunto de dados em questão refere-se à imagens de pílulas ilícitas de diversas formas separadas em 5 grupos: Alprazolam, Dominó, Medium Cut, Tesla e Warner Bros.

2. Segmentação por Crescimento de Regiões

O processo de Segmentação por Crescimento de Regiões é, de certa forma, bem simples. Inicialmente é preciso selecionar um conjunto de pontos para compor o que chamamos de semente que por sua vez, nada mais é que o conjunto de pixels que são inicialmente incorporadas à região que será expandida. Esta expansão ocorre mediante a um critério que chamaremos de Critério de Agrupamento. Mais abaixo explicaremos como a semente foi obtida e qual o critério de agrupamento utilizado.

2.1 Obtenção da Semente e Critério de Agrupamento

Para a obtenção das sementes verificamos que, em nenhuma das imagens do conjunto de dados, o objeto de interesse aparece em suas bordas laterais. Assim, optamos por posicionar o conjunto de pixels nestas duas bordas. A Figura 1 ilustra este processo. Feito o posicionamento da borda, partimos para o Critério de Agrupamento.

De forma simples, utilizamos um critério baseado em um limiar que chamaremos de e . Assim, se a diferença entre um determinado pixel $P(x, y)$ e um de seus pixels vizinhos $PI(x_1, y_1)$ for menor ou igual a este limiar, PI será agrupado, caso contrário, PI não será agrupado indicando que este pixel faz parte do fundo da imagem e não do objeto de interesse.




Figura 1. *Posicionamento da Semente*

O limiar foi conseguido de forma automática, isto é, adaptando-se às características das pílulas da seguinte forma: inicialmente foram feitos “cortes” horizontais na imagem em questão, como ilustrado na Figura 2. Feito isto, foram capturados todos os pixels pertencentes à este corte bem como seus pixels vizinhos. Desta forma, podemos calcular a média das intensidades de cinza entre as diferenças de intensidade de um determinado pixel P todos os seus vizinhos. Feita esta média, podemos obter um limiar razoável que se adapta às variações de níveis de cinza das imagens.




Figura 2. *Cortes na imagem para obtenção de um limiar*

3. Segmentação utilizando Transformada de Hough

Utilizaremos a transformada de Hough para detecção de pílulas circulares. Para isso utilizaremos o método *HoughCircles* da biblioteca OpenCV, que possui a seguinte assinatura:

cv2.HoughCircles(image, method, dp, minDist, param1, param2, minRadius, maxRadius)

Dentre esses parâmetros destacamos os seguintes: *minDist*, que representa a mínima distância entre dois círculos diferentes; *minRadius*, que representa o tamanho mínimo do raio de cada círculo; e *maxRadius*, que representa o tamanho máximo do raio de cada círculo. O método *HoughCircles* tem como um retorno uma lista de vetores contendo as coordenadas do centro e o tamanho do raio de cada círculo. Através dessas informações podemos desenhar o círculo na imagem original e binarizar a mesma. Vale lembrar que utilizamos um filtro da mediana de tamanho 5 para diminuir o ruído das imagens antes de aplicar a transformada de Hough. Abaixo vemos um exemplo de aplicação do método.




Figura 3. Aplicação do método *HoughCircles*

3.1 Acurácia do método de Hough

Calculamos a acurácia do método utilizado de acordo com a seguinte fórmula:

$$\frac{VP + VN}{VP + VN + FP + FN}$$

Onde:

VP = Verdadeiro Positivo

VN = Verdadeiro Negativo

FP = Falso Positivo

FN = Falso Negativo

Os testes foram realizados em um total de 37 pílulas do tipo *medium cut* e o resultado pode ser visto abaixo:

$$\frac{VP + VN}{VP + VN + FP + FN} = \frac{31 + 0}{31 + 0 + 5 + 1} \approx 0.873 = 87.3\%$$

4. Segmentação utilizando K-Means

O K-Means (ou K-Médias) é um método de agrupamento que objetiva particionar n observações dentre k grupos onde cada observação pertence ao grupo mais próximo da média. Isso resulta em uma divisão do espaço de dados em um Diagrama de Voronoi. Para segmentação das imagens em questão, este método foi utilizado para agrupar e colorir pixels do objeto de interesse, que nesse

caso são pílulas ilícitas, bem como agrupar e colorir pixels do fundo da imagem. Este processo será melhor detalhado abaixo.

4.1 Funcionamento e implementação do método

Iniciamos o algoritmo definindo, manualmente, centróides. Estes centróides serão o valor médio da intensidade dos pixels representantes de cada grupo. Assim, queremos dividir os pixels da imagem em questão em três grupos. A decisão sobre a quantidade de grupos foi tomada em virtude da variação de intensidade dos que a maioria das imagens possui. Além disso, algumas imagens possuem bordas escuras e sombras. Feita esta definição, o método é iniciado percorrendo todos os pixels da imagem e calculando a diferença de intensidade entre este pixel e os centróides em. O pixel com menor diferença com o centróide será adicionado ao seu grupo. Após percorrer toda a imagem realizando o método descrito acima, devemos atualizar os centróides. Esta atualização ocorre de forma simples. Os novos centróides serão as médias de das intensidades de todos o pixels adicionados anteriormente. Este processo ocorre iterativamente por uma determinada quantidade de vezes. A saída deste método será a imagem segmentada.

5. Resultados

Nesta seção apresentaremos os resultados para os três métodos de segmentação descritos acima. Primeiramente mostraremos algumas imagens e os resultados da segmentação realizada por cada um dos métodos. Logo depois mostramos alguns atributos calculados na imagem segmentada.

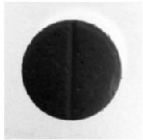
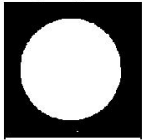
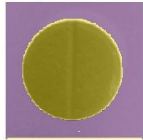

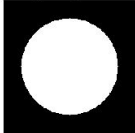


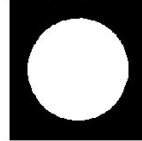

5.1 Imagens segmentadas

Em geral, todos os três métodos de segmentação apresentados neste documento funcionam muito bem quanto a imagem a ser segmentada em tons de cinza, possui seu objeto de interesse com intensidade de pixels do seu fundo, como a Figura 4 mostra.



Figura 4. *Pílula a ser segmentada*

Tabela 1. *Resultado de segmentação*





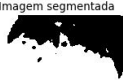

Método de segmentação	Resultado		
Crescimento de Região	<div>Original em tons de cinza</div> 	<div>Imagem segmentada</div> 	<div>Região Segmentada</div> 
Transformada de Hough	<div>Original em tons de cinza</div> 	<div>Imagem segmentada</div> 	<div>Região Segmentada</div> 
K-Means	<div>Original em tons de cinza</div> 	<div>Imagem segmentada</div> 	<div>Região Segmentada</div> 

Já para imagens as quais o objeto de interesse possui intensidade próxima a intensidade do fundo (como mostra a Figura 5), ou se a imagem é muito ruidosa ou possui sombra, os método acima não são tão eficientes.



Figura 5. *Pílula a ser segmentada*

Tabela 2. Resultado de segmentação

Método de segmentação	Resultado
Crescimento de Região	<div>Original em tons de cinza</div>  <div>Imagem segmentada</div>  <div>Região Segmentada</div> 
Transformada de Hough	O círculo não foi detectado.
K-Means	<div>Original em tons de cinza</div>  <div>Imagem segmentada</div>  <div>Região Segmentada</div> 

5.2 Atributos Médios

Aqui mostraremos os resultados médios para os cálculos de alguns atributos das imagens segmentadas. Aplicamos a transformada de Hough apenas nas imagens circulares visto que este método visa encontrar círculos, como explicado anteriormente na seção 3.

Tabela 3. Atributos médios da segmentação por crescimento de região

CRESCIMENTO DE REGIÃO	Área Média	Razão Área/Perímetro	Circularidade Média	Desvio Padrão Médio
Alprazolam	9218.7	28.673	1.196	46.790
Dominó	14725.687	33.213	1.043	43.110
Medium Cut	12154.567	1060.146	12915.355	36.764
Tesla	13376.654	233.099	366.118	34.633
Warner Bros	18902.389	2148.154	26411.95	33.469

Tabela 4. *Atributos médios da segmentação por Transformada de Hough*

TRANSFORMADA DE HOUGH	Área Média	Razão Área/Perímetro	Circularidade Média	Desvio Padrão Médio
Alprazolam	-	-	-	-
Dominó	-	-	-	-
Medium Cut	15010.006	33.805	1.0	29.796
Tesla	-	-	-	-
Warner Bros	-	-	-	-

Tabela 5 *Atributos médios da segmentação por K-Médias*

K-MÉDIAS	Área Média	Razão Área/Perímetro	Circularidade Média	Desvio Padrão Médio
Alprazolam	18138.9	43.396	1.9217	28.967
Dominó	25768.437	31.926	0.659	26.522
Medium Cut	20830.973	4.454	0.802	25.350
Tesla	29544.385	29.729	0.507	27.911
Warner Bros	25487.667	2246.73	27925.65	23.107

6. Conclusão

De forma geral, os métodos apresentados obtiveram sucesso na tarefa de segmentar as imagens submetidas quando estas apresentam uma certa quantidade de ruído e o objeto de interesse pôde ser destacado do fundo. No entanto, mesmo algumas imagens com uma quantidade alta de ruído puderam ser segmentadas de forma aceitável.